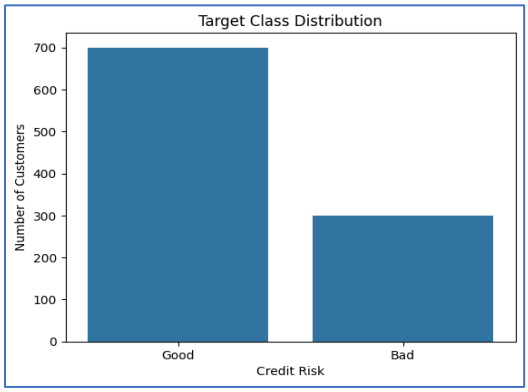
خلاصه مدیریتی

هدف این پروژه طراحی یک سیستم هوشمند برای ارزیابی ریسک اعتباری مشتریان بانک و شناسایی افرادی است که احتمال عدم بازپرداخت تسهیلات توسط آن‌ها بالاتر است. این سیستم با تحلیل اطلاعات مالی و اعتباری مشتریان و استفاده از یک رویکرد پیش بینی مبتنی بر الگوریتم های درختی، تلاش می‌کند الگو های مرتبط با بد حسابی را شناسایی کرده و پیش از تصمیم‌گیری ، دید دقیق تری از میزان ریسک هر مشتری ارائه دهد. نتایج ارزیابی نشان می‌دهد سیستم توانسته است حدود سه چهارم مشتریانی را که واقعاً در بازپرداخت تسهیلات مشکل داشته اند، شناسایی کند؛ به این معنا که از هر چهار مشتری بدحساب، تقریباً سه نفر توسط سیستم به‌عنوان مشتری پرریسک تشخیص داده شده اند. این قابلیت می‌تواند به بهبود فرآیند اعتبارسنجی، شناسایی زود هنگام مشتریان پرریسک و مدیریت بهتر ریسک اعطای تسهیلات کمک کند.

تحلیل کلیدی داده ها :

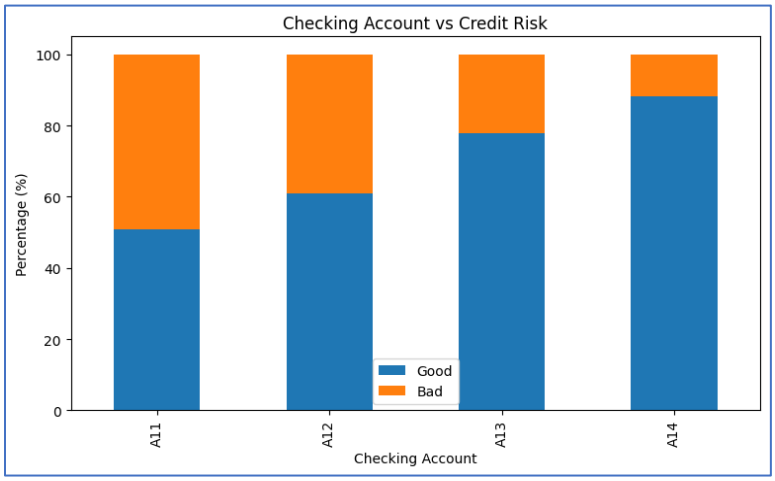
بررسی توزیع مشتریان نشان می‌دهد که از مجموع ۱۰۰۰ مشتری موجود در داده ها، ۷۰ درصد دارای وضعیت بازپرداخت مطلوب و ۳۰ درصد دارای وضعیت بازپرداخت نامطلوب هستند. به بیان دیگر، تقریباً از هر سه مشتری، یک نفر در گروه مشتریان بدحساب قرار دارد. این موضوع اهمیت شناسایی صحیح مشتریان پرریسک را در فرآیند ارزیابی و اعطای تسهیلات نشان می‌دهد.



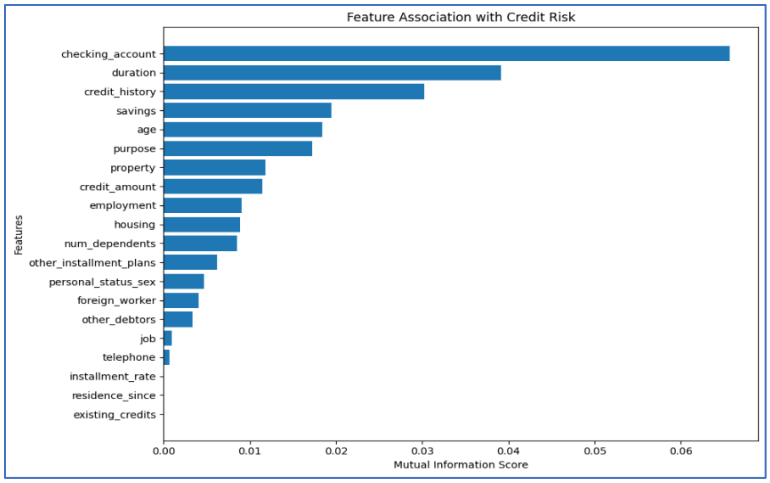
مشتریان بر اساس وضعیت حساب جاری به چهار گروه تقسیم شده‌اند:

- کلاس A11 : مشتریانی که موجودی حساب جاری آن‌ها کمتر از صفر است.
- کلاس A12 : مشتریانی که موجودی حساب جاری آن‌ها بین صفر تا ۲۰۰ مارک آلمان است.
- کلاس A13 : مشتریانی که موجودی حساب جاری آن‌ها حداقل ۲۰۰ مارک آلمان است یا حقوق آن‌ها حداقل به مدت یک سال به حسابشان واریز شده است.
- کلاس A14 : مشتریانی که فاقد حساب جاری در بانک هستند.

بررسی رابطه وضعیت حساب جاری با نرخ بدحسابی نشان می‌دهد که میزان موجودی حساب مشتریان می‌تواند اطلاعات مفیدی درباره ریسک بازپرداخت تسهیلات ارائه دهد. به‌طوری‌که نرخ بدحسابی در میان مشتریانی که موجودی حساب آن‌ها منفی است، حدود ۴۹ درصد بوده، درحالی‌که این میزان برای مشتریان دارای موجودی حداقل ۲۰۰ مارک یا واریز حقوق منظم حدود ۲۲ درصد است. همچنین مشتریان فاقد حساب جاری در این مجموعه داده، نرخ بدحسابی حدود ۱۲ درصدی داشته‌اند. این تفاوت‌ها نشان می‌دهد وضعیت حساب جاری می‌تواند یکی از شاخص‌های مؤثر در ارزیابی ریسک اعتباری مشتریان باشد.



برای بررسی جامع‌تر عوامل مرتبط با ریسک اعتباری، میزان ارتباط ویژگی های مختلف با وضعیت بازپرداخت مشتریان با استفاده از معیار اطلاعات متقابل (Mutual Information) مقایسه شده است. نتایج نشان می‌دهد که وضعیت حساب جاری مشتری (checking_account) بیشترین ارتباط را با وضعیت بازپرداخت دارد. پس از آن، مدت بازپرداخت وام (duration) و سابقه اعتباری مشتری (credit_history) در رتبه‌های بعدی قرار گرفته‌اند. همچنین ویژگی‌هایی مانند میزان پس‌انداز مشتری (savings)، سن مشتری (age) و هدف دریافت وام (purpose) نیز از ارتباط قابل‌توجهی با ریسک اعتباری برخوردارند. در مقابل، برخی ویژگی‌ها مانند نرخ اقساط نسبت به درآمد (installment_rate) ، مدت سکونت در محل فعلی (residence_since) و تعداد وام‌ها یا اعتبارات موجود (existing_credits) ارتباط بسیار محدودی با متغیر هدف نشان داده‌اند. این بررسی به شناسایی ویژگی‌های اطلاعاتی‌تر برای ارزیابی ریسک اعتباری کمک می‌کند.



مقایسه مدل‌ها و انتخاب مدل نهایی

در مرحله اول، یک مدل درخت تصمیم ساده (Decision Tree) برای ارزیابی اولیه ریسک مشتریان طراحی کردیم. این مدل توانست حدود ٪۷۹ از پیش‌بینی‌های خود را به‌درستی انجام دهد. همچنین از میان مشتریانی که پرریسک تشخیص داده شدند، حدود ٪۶۵ واقعاً بدحساب بودند و مدل توانست ٪۶۳ از کل مشتریان بدحساب را شناسایی کند. این نتایج نشان دادند که مدل پایه عملکرد قابل قبولی دارد، اما هنوز بخشی از مشتریان بدحساب را شناسایی نمی‌کند و ممکن است باعث ایجاد ضرر برای بانک شود.

در مرحله بعد، از مدل پیشرفته‌تر Random Forest استفاده کردیم. این مدل با دقت کلی حدود ٪۸۱ عملکرد بهتری نسبت به مدل قبلی داشت. همچنین توانست ٪۷۵ از مشتریان بدحساب را شناسایی کند؛ در حالی که این مقدار در مدل قبلی ٪۶۳ بود. به بیان ساده، مدل جدید توانست تعداد بیشتری از مشتریانی را که احتمال بازپرداخت نکردن تسهیلات آن‌ها وجود دارد، پیش از اعطای وام شناسایی کند. این موضوع می‌تواند احتمال اعطای تسهیلات به مشتریان پرریسک و در نتیجه زیان‌های ناشی از عدم بازپرداخت را کاهش دهد.

در ادامه، برای کاهش بیشتر ریسک مالی بانک، نسخه دیگری از مدل Random Forest را با رویکردی سخت‌گیرانه‌تر بررسی کردیم. در این روش، مدل طوری تنظیم شد که نسبت به احتمال بدحساب بودن مشتری حساسیت بیشتری داشته باشد؛ به این معنا که حتی در مواردی که نشانه‌های ریسک چندان قوی نیستند، در صورت وجود احتمال نکول، مشتری را در گروه پرریسک قرار دهد. نتایج نشان داد این مدل توانست حدود ٪۹۸ از مشتریان بدحساب را شناسایی کند؛ یعنی از هر ۱۰۰ مشتری بدحساب، تقریباً ۹۸ نفر را تشخیص دهد. در مقابل، دقت آن در شناسایی مشتریان خوش‌حساب پایین‌تر بود و تعداد زیادی از این مشتریان نیز به اشتباه پرریسک تشخیص داده شدند.

با توجه به اینکه در این پروژه هزینه اشتباه در شناسایی یک مشتری بدحساب پنج برابر هزینه اشتباه در شناسایی یک مشتری خوش‌حساب در نظر گرفته شده است، استفاده از این رویکرد سخت‌گیرانه می‌تواند به کاهش قابل توجه زیان‌های احتمالی بانک

کمک کند. بنابراین، این مدل با وجود اینکه ممکن است باعث از دست رفتن تعدادی از مشتریان خوش‌حساب و فرصت‌های درآمدزایی بانک شود، در شناسایی و جلوگیری از پذیرش مشتریان پرریسک عملکرد بسیار بهتری دارد.

در مجموع، مدل Random Forest با رویکرد سخت‌گیرانه‌تر، به دلیل توانایی بالاتر در شناسایی مشتریان بدحساب و کاهش ریسک عدم بازپرداخت تسهیلات، گزینه مناسب‌تری برای شرایطی است که اولویت اصلی بانک کاهش زیان‌های اعتباری باشد. البته اجرای چنین سیاستی باید با در نظر گرفتن هزینه از دست دادن مشتریان خوش‌حساب همراه باشد.

تحلیل عوامل مؤثر بر تصمیم مدل با استفاده ازSHAP

برای بررسی دلایل تصمیم‌گیری مدل و شناسایی عواملی که بیشترین نقش را در پیش‌بینی ریسک مشتریان دارند، از روش SHAPاستفاده کردیم. این روش به ما کمک می‌کند علاوه بر شناخت مهم‌ترین ویژگی‌های مؤثر بر تصمیم مدل، تأثیر هر ویژگی بر افزایش یا کاهش ریسک پیش‌بینی‌شده را نیز بررسی کنیم.

نتایج نمودار اهمیت ویژگی‌ها (SHAP Bar Plot) نشان داد که liquidity_profileبیشترین تأثیر را در تصمیم‌گیری مدل دارد. پس از آن، ویژگی‌های checking_account، duration، credit_profileو ageدر رتبه‌های بعدی قرار گرفتند. این نتایج نشان می‌دهد وضعیت مالی مشتری، شرایط حساب جاری، مدت بازپرداخت تسهیلات و سابقه اعتباری از مهم‌ترین اطلاعات مورد استفاده مدل برای ارزیابی ریسک هستند.

همچنین ویژگی‌هایی مانند num_dependents، foreign_worker و telephone تأثیر بسیار کمتری در پیش‌بینی‌های مدل داشته‌اند.

در ادامه برای درک بهتر نحوه تصمیم‌گیری مدل، دو مشتری را به‌صورت جداگانه بررسی کردیم؛ یک مشتری بدحساب که به‌درستی پرریسک تشخیص داده شده و یک مشتری خوش‌حساب که به‌درستی کم‌ریسک شناسایی شده است. برای این کار از نمودار Waterfall استفاده کردیم تا مشخص شود هر یک از ویژگی‌های مشتری چگونه بر نتیجه نهایی مدل تأثیر گذاشته‌اند.

نمونه اول: مشتری بدحساب

در نمونه اول، مشتری مورد بررسی واقعاً بدحساب بوده و مدل نیز او را در گروه پرریسک قرار داده است. احتمال اولیه مدل برای بدحساب بودن مشتری ٪۴۶٫۳ بوده که پس از بررسی ویژگی‌های او به ٪۶۶٫۹ افزایش پیدا کرده است.

بررسی نمودار نشان داد ویژگی‌هایی مانند وضعیت نقدینگی، سابقه اعتباری، وضعیت حساب جاری و سایر اطلاعات مالی مشتری در افزایش ریسک پیش‌بینی‌شده نقش داشته‌اند. این موضوع نشان می‌دهد مدل توانسته با بررسی مجموعه‌ای از اطلاعات مشتری، نشانه‌های مرتبط با ریسک بالای بازپرداخت را شناسایی کند.

نمونه دوم: مشتری خوش‌حساب

در نمونه دوم، یک مشتری خوش‌حساب را بررسی کردیم که مدل نیز او را به‌درستی در گروه کم‌ریسک قرار داده است. احتمال اولیه بدحساب بودن مشتری ۴۶٫۳٪ بود، اما پس از بررسی ویژگی‌های او، این مقدار به ۵٫۶٪ کاهش پیدا کرد.

طبق نمودار، وضعیت نقدینگی مشتری با کاهش حدود ۰٫۰۰۷، وضعیت حساب جاری با کاهش حدود ۰٫۰۰۶ و مدت باقی‌مانده بازپرداخت و سابقه اعتباری هر کدام با کاهش حدود ۰٫۰۰۵، از مهم‌ترین عوامل کاهش ریسک پیش‌بینی‌شده بودند. همچنین سن و مبلغ اعتبار نیز در کاهش این ریسک نقش داشتند.

این نتیجه نشان می‌دهد که مدل توانسته با بررسی شرایط مختلف مشتری، نشانه‌های مرتبط با ریسک پایین‌تر را شناسایی کند و احتمال بدحساب بودن او را به میزان قابل توجهی کاهش دهد.

